

DAT 6기 캡스톤 프로젝트 보고서

Two-Track 기반 End-to-End 수어 번역 시스템 개발

: 고해상도 영상 특징 추출과 경량 랜드마크 모델의 병렬 설계를 통한 성능 최적화 연구

DAT 6기

수자인(Sujain)

이서희

길다인

김채린

이종민



Data Analysis & Technology



DAT 6기 캡스톤 프로젝트 보고서

Two-Track 기반 End-to-End 수어 번역 시스템 개발

: 고해상도 영상 특징 추출과 경량 랜드마크 모델의 병렬 설계를 통한 성능 최적화 연구

Development of a Two-Track Based End-to-End

Sign Language Translation System

: A Study on Performance Optimization through Parallel Design of High-Resolution
Video Feature Extraction and Lightweight Landmark Models

이 보고서를 캡스톤 프로젝트 보고서로 제출합니다.

2025년 12월 01일

DAT 6기

수자인(Sujain)

이서희

길다인

김채린

이종민



Data Analysis & Technology



Two-Track 기반 End-to-End 수어 번역 시스템 개발

: 고해상도 영상 특징 추출과 경량 랜드마크 모델의 병렬 설계를 통한 성능 최적화 연구

국문 요약

본 연구는 연속 수어 영상을 자연어 문장으로 번역하기 위한 End-to-End 수어 번역 모델을 구축하고, RGB 기반(Track A)과 랜드마크 기반(Track B)의 두 접근 방식을 비교·검증하였다. 데이터는 How2Sign과 DailyMoth-70h의 대규모 ASL-영어 병렬 코퍼스를 활용하였으며, 영상-텍스트 정합, 랜드마크 추출, 시퀀스 전처리 등 통합 파이프라인을 구축하였다. Track A에서는 VideoMAE를 활용한 오프라인 특징 추출과 Adapter 학습을 통해 제한된 GPU 환경에서도 영상 기반 번역을 구현하였다. Track B에서는 MediaPipe 랜드마크를 정규화하여 경량 Transformer에 입력함으로써 연산 효율성과 실시간성을 확보하였다. 실험 결과 Track A는 영상 기반 특징의 제약으로 인해 일관된 문장 생성 성능 확보가 어려웠으며, Track B는 효율성 측면의 강점에도 불구하고 특정 도메인 문장에 편향되어 수어 의미 반영이 제한되는 경향이 나타났다. 본 연구는 Two-Track 구조를 통해 수어 번역의 정확도와 효율성 간의 균형점을 탐색하였으며 향후 멀티모달 모델 적용과 데이터 확장을 통해 성능을 더욱 개선할 수 있는 가능성을 제시한다.

Abstract

This study proposes an end-to-end sign language translation framework comparing two approaches: an RGB-based pipeline (Track A) and a landmark-based pipeline (Track B). Using the How2Sign and DailyMoth-70h corpora, we construct a unified preprocessing pipeline for video-text alignment, landmark extraction, and sequence preparation. Track A leverages VideoMAE features with adapter-based training under limited GPU resources, while Track B uses normalized MediaPipe landmarks with a lightweight Transformer for real-time efficiency. Experiments show that Track A produces inconsistent sentence-level translations due to visual feature constraints, whereas Track B, despite its efficiency, exhibits domain-specific biases. Overall, the Two-Track design highlights the trade-off between accuracy and efficiency and suggests multimodal integration and larger datasets as promising directions.

DAT 6기

수자인(Sujain)

이서희

길다인

김채린

이종민



Data Analysis & Technology



목 차

제 1장 서론	1
제 1절 연구 배경 및 연구 목적	1
제 2장 데이터 소개.....	3
제 1절 데이터셋 개요.....	3
제 2절 전처리 과정.....	4
제 3장 연구 방법론.....	6
제 1절 모델 전체 파이프라인 개요.....	6
제 2절 학습 설정 및 하이퍼파라미터 & 평가 지표 및 실험 환경.....	10
제 4장 결론.....	14
제 1절 연구 결과 및 보고.....	14
제 2절 한계점 및 향후 연구 방향.....	19
참고문헌.....	22

표 목차

표 1. Track B 주요 성능 지표.....	17
표 2. 실험 구성 및 비교군 설정.....	18

그림 목차

그림 1. 비디오 기반 영상 번역 모델 파이프라인.....	6
그림 2. 랜드마크 기반 영상 번역 모델 파이프라인.....	8
그림 3. Track A 최종 모델 결과 및 시연 예시.....	14
그림 4. Track B 최종 모델 결과 (Loss, BLEU 측정).....	15

[1]



그림 5. Track B 시연 예시.....	16
--------------------------	----



제 1 장 서론

제 1 절 연구 배경 및 연구 목적

1.1.1 연구 배경

수어(Sign Language)는 손동작뿐 아니라 얼굴 표정, 시선, 신체 방향, 상체 움직임이 함께 조합되어 의미가 형성되는 고도로 복합적인 시각·언어적 체계로, 음성·텍스트 기반 자연어 처리 기법을 직접 적용하기 어렵고 영상 속 다양한 신체 부위를 동시에 이해해야 하는 고난도의 분석 문제를 제기한다. 특히 양손의 비동기적 움직임, 프레임 단위의 동작 변화, 조음 위치의 이동 등 시계열·공간 정보가 모두 의미에 기여하므로 단순 제스처 인식이 아닌 독립적인 언어 처리 문제로 다뤄져야 한다. 최근 딥러닝의 발전과 함께 수어 인식·번역 연구가 활발히 진행되고 있으나, 언어별 차이, 수화 방식의 다양성, 대규모 병렬 코퍼스 부족, 촬영 환경의 편차 등으로 인해 데이터 학습 난도가 높고, 기존의 영상 기반 모델은 미세 손가락 움직임이나 얼굴 특징을 충분히 포착하지 못하며 텍스트 분포에 과도하게 의존한 문장 생성 문제가 보고되고 있다. 이러한 한계를 보완하기 위해 멀티모달 학습, 경량 랜드마크 기반 모델, VideoMAE 와 같은 사전학습 기반 비디오 표현 학습이 주요 연구 흐름으로 부상하고 있으며, RGB 영상이 풍부한 시각 정보를 제공하는 반면, 랜드마크 입력은 배경·잡음의 영향을 줄여 동작의 구조적 패턴을 더 명확히 표현할 수 있어 효율성과 실시간성 측면에서 중요한 장점을 가진다. 본 연구에서는 이러한 수어 번역의 구조적 복잡성과 입력 모달리티의 차이를 고려하여, RGB 기반(Track A)과 랜드마크 기반(Track B)이라는 두 가지 상이한 접근을 병렬로 실험하는 Two-Track 전략을 수행하였다. 이를 통해 데이터 표현 방식에 따른 번역 성능의 차이를 분석하고, 수어 번역 모델이 가지는 실제적 한계와 가능성을 균형 있게 탐색하고자 한다.

1.1.2 연구 목적

수어는 손·얼굴·신체가 동시에 움직이며 의미를 구성하는 복합적 시각 언어로, 이를 자연어 문장으로 정확히 번역하기 위해서는 다양한 수준의 시각 정보를 통합적으로 처리할 수 있는 모델이 필요하다. RGB 기반 영상 입력은 풍부한 정보를 제공하지만 연산 비용이 크고, 랜드마크 기반 입력은 효율적이지만 정보 손실 가능성이 존재하는 만큼 단일 접근 방식만으로는 안정적이고 확장 가능한 번역 시스템을 구축하기 어렵다. 본 연구는 이러한 한계를 해결하기 위해 RGB 기반(Track A)과 랜드마크



기반(Track B)이라는 두 입력 모달리티를 비교 및 검증하는 Two-Track 전략을 채택하고, VideoMAE 기반 영상 특징 추출과 MediaPipe 랜드마크 정규화 등 최신 기법을 활용하여 두 접근 방식의 표현력, 효율성, 번역 성능상의 차이를 체계적으로 분석하고자 한다. 이를 통해 수어 번역 모델이 지향해야 할 정확도, 연산 효율성, 실시간성 간의 균형점을 탐색하고 향후 멀티모달 결합과 대규모 데이터 확장 등 발전 가능성을 제시하는 것을 연구의 목적으로 한다.



제 2 장 데이터 소개

제 1 절 데이터셋 개요

본 연구에서는 미국 수어(ASL)의 연속 수어 영상과 영어 문장이 매칭된 병렬 코퍼스를 활용하여 End-to-End 수어 번역 모델을 학습하였다. 데이터는 서로 다른 도메인과 촬영 환경을 가진 How2Sign 과 DailyMoth-70h 두 유형으로 구성된다. 두 데이터셋 모두 문장 단위의 수어 영상과 영어 번역문이 정렬되어 있어 수어 번역 모델 학습에 적합한 구조를 가진다.

How2Sign(Duarte et al., 2021)은 약 80 시간 분량, 35,191 개 문장 쌍으로 구성된 대규모 멀티모달 연속 수어 데이터셋이다. 9 명의 원어민 수어 화자가 크로마키 스튜디오 환경에서 촬영한 정면·측면 RGB 비디오, 깊이 영상뿐 아니라 신체·손·얼굴의 2D/3D 골격 랜드마크, 글로스 주석 등 다양한 모달리티 정보를 제공한다. 데이터는 문장 단위로 분리되어 있으며, 제공된 train/validation/test 분할을 그대로 활용하였다.

DailyMoth-70h(Uthus et al., 2023)은 약 70 시간 분량의 뉴스 분야 연속 수어 데이터셋으로, 동일 화자가 진행한 뉴스 영상을 기반으로 한다. 모든 영상은 영어 캡션과 정확히 정렬되어 있으며, 문장 구간 단위로 분할 시 train 41,046 개, validation 2,490 개, test 4,122 개의 문장-영상 쌍을 제공한다. How2Sign 과 비교하여 도메인이 명확하고 화자 변이가 적어 모델이 학습하는 언어적·시각적 패턴이 일관된다는 특징이 있다.

본 연구는 두 데이터셋의 원본 영상과 영어 문장 정보를 통합적으로 활용하여 학습용 manifest 를 구축하고, 각 트랙의 목적에 따라 데이터를 구성하였다. How2Sign 은 RGB 입력 및 랜드마크 기반 실험 모두에 사용하였고, DailyMoth-70h 는 전체 manifest 를 구축한 뒤 연산 비용을 고려하여 Track B 용 랜드마크 추출에 한해 일부 샘플을 무작위로 선정하였다. 두 데이터셋을 병렬 활용함으로써 생활 회화부터 뉴스까지 다양한 도메인을 포함하는 풍부한 학습 데이터를 확보할 수 있었으며, 이는 모델의 일반화 능력 향상에 기여하였다.



제 2 절 전처리 과정

본 연구에서는 수어 영상과 대응되는 텍스트 문장을 효율적으로 학습 데이터로 구성하기 위해, 원본 영상과 자막 정보를 정합하여 문장 단위의 manifest 를 구축하고 각 Track 의 특성에 따라 랜드마크 기반 좌표 시계열(Track B)과 영상 기반 특징 벡터(Track A)를 생성하는 전처리 과정을 수행하였다. 전체 절차는 (1) 수어 영상-텍스트 구간 정합 및 manifest 구축, (2) 랜드마크 좌표 추출 및 시계열 데이터화(Track B), (3) 영상 특징 추출 및 입력 벡터화(Track A)로 구성된다.

2.2.1 수어 영상-텍스트 구간 정합 및 Manifest 구축

본 연구에서는 How2Sign 과 DailyMoth-70h 에서 제공되는 영상-텍스트 병렬 데이터를 기반으로, 학습에 필요한 영상 구간과 번역문을 정확히 대응시키는 manifest 파일을 구축하였다. How2Sign 의 경우 전체 데이터셋이 방대하므로 연구 목적에 맞게 train-validation-test 세트에서 각각 8,000/1,000/1,000 개를 무작위로 샘플링해 활용하였으며, DailyMoth-70h 는 제공된 원본 구성(train 41,046 개, validation 2,490 개, test 4,122 개)을 그대로 사용하였다. Manifest 파일은 각 샘플의 영상 경로와 해당 구간의 정렬된 영어 문장을 함께 기록하여 하나의 통합된 참조 구조를 형성하며, 이후 단계에서 생성되는 비디오 특징이나 랜드마크 특징 파일 경로도 동일한 구조 안에서 연결될 수 있도록 설계되었다. 이를 통해 Track A와 Track B가 서로 다른 입력 형식을 사용하더라도 동일한 영상-텍스트 매칭 정보를 공유하면서 독립적으로 데이터 로딩과 전처리를 수행할 수 있는 기반을 마련하였다.

2.2.2 랜드마크 좌표 추출 및 시계열 데이터화

Track B 에서는 영상 프레임 단위의 시각 정보를 직접 활용하지 않고, 수어 동작의 구조적 특징을 안정적으로 학습하기 위해 MediaPipe Holistic 을 사용하여 얼굴·포즈·양손의 랜드마크 좌표를 추출하였다. 원본 mp4 영상의 전체 프레임을 순차적으로 처리하며 각 프레임에서 543 개의 랜드마크 좌표를 획득하였고, 이를 기반으로 프레임별 시계열 형태의 좌표 배열을 구성하였다. 이후 모델 입력 효율성을 높이기 위해 전체 랜드마크 중 수어 표현에 핵심적인 관절·손동작 중심의 서브셋을 선택하여 2D 좌표(x, y)만을 보존하였다. 정제된 랜드마크 시퀀스는 영상 길이에 맞추어 고정 길이 시계열로 정렬된 뒤 numpy 기반의 .npy 파일로 저장되었으며, 이후 Transformer 기반 Encoder 의 입력으로



직접 활용되었다. 이러한 절차를 통해 RGB 영상 대비 훨씬 경량화된 구조적 표현을 구축함으로써 Track B 모델은 연산 자원을 크게 절감하면서도 수어 동작의 시간적 변화 패턴을 효과적으로 학습할 수 있는 기반을 확보하였다.

2.2.3 영상 특징 추출 및 입력 벡터화

Track A에서는 RGB 기반 수어 영상을 직접 모델에 입력하기 위해, 원본 mp4 파일을 일정한 프레임 간격으로 추출하여 정규화된 시각 시퀀스로 변환하였다. 프레임 단위의 영상은 크기 조정 및 픽셀 값 스케일링을 거쳐 VideoMAE(Video Masked AutoEncoder)의 입력 형식에 맞추어 전처리되었으며, 이후 사전학습된 VideoMAE Encoder를 활용하여 각 영상 클립을 잠재 표현(latent feature)으로 변환하였다. 이렇게 추출된 고정 길이의 영상 특징 벡터는 Transformer 기반 Decoder와 연동될 수 있도록 시계열 형태로 재배열되었고, 학습 중 Adapter 모듈을 추가하여 제한된 GPU 메모리 환경에서도 영상 기반 번역 모델이 동작하도록 하였다. 최종적으로 생성된 영상 특징 시퀀스는 텍스트 Decoder의 입력과 정렬될 수 있는 형태로 구성되어 Track A의 번역 모델 학습에 사용되었다.



제 3 장 연구 방법론

제 1 절 모델 전체 파이프라인 개요

3.1.1 Track A: RGB 기반 영상 번역 파이프라인




그림 1. 비디오 기반 영상 번역 모델 파이프라인

본 연구의 Track A 는 RGB 기반 수어 영상을 입력으로 하여 자연어 문장을 생성하는 End-to-End 번역 모델을 구축하였다. 전체 파이프라인은 (1) 영상 전처리 및 프레임 구성, (2) VideoMAE 기반 오프라인 특징 추출, (3) Adapter 기반 특징 변환 및 시퀀스 정규화, (4) T5 Decoder 를 통한 문장 생성의 네 단계로 구성된다. Track A 는 대규모 비전 언어 모델과의 결합을 위해, 원본 영상 처리 부담을 줄이는 전략을 채택하였으며, 사전학습된 VideoMAE 의 표현력을 유지하면서도 경량 환경에서 학습이 가능하도록 파이프라인을 설계하였다.

(1) 영상 전처리 및 입력 영상 구성

먼저 수어 영상(mp4)을 일정한 길이의 프레임 시퀀스로 변환하였다. 모델 입력의 일관성을 유지하기 위해 모든 영상은 동일한 프레임 수로 샘플링되었으며, 영상 크기 또한 VideoMAE 의 입력 해상도 기준에 맞게 정규화되었다. Track A 는 원본 RGB 데이터를 직접 사용하기 때문에, 배경·의복·조명 변화가 포함된 실제 영상 환경을 그대로 반영하며, 이를 통해 시각적 문맥 정보(손 모양, 위치, 움직임, 표정 등)를 모두 활용할 수 있는 구조를 갖는다.

(2) VideoMAE 기반 오프라인 특징 추출

영상 전처리 후, 사전학습된 VideoMAE-Base(Kinetics-400 pretrained)를 활용해 각 영상 클립에서 잠재 표현을 추출하였다. GPU 메모리 사용량을 최소화하기 위해 VideoMAE 는 학습 과정에서 동결(frozen)되었으며, 모든 영상에 대해 오프라인 방식으로 특징 벡터를 미리 생성하여 저장(.npy)하였다. 이러한 전략은 학습 중 비전 인코더를 반복 실행할 필요를 제거하여, 제한된 GPU 환경에서도 대규모 비디오 모델의 표현력을 활용할 수 있게 한다. VideoMAE 가 생성한 특징 벡터는 각 프레임의 시각 정보를 압축한 고차원 시퀀스로 구성되며, 이후 Transformer 기반 번역 모델의 입력으로 사용될 준비를 갖춘다.

(3) Adapter 기반 시퀀스 변환 및 특징 정규화

VideoMAE 가 출력한 원시 비디오 특징은 곧바로 자연어 생성 Decoder 에 전달하기 어렵기 때문에, 본 연구에서는 Adapter 모듈을 활용해 특징을 변환하고 시퀀스 구조를 정돈하였다. Adapter 는 단순 선형 변환이 아니라, Conv1d 와 Transformer Encoder 블록을 결합하여 시간적 정보(동작의 연속성)와 지역적 패턴(손·팔의 미세 변화)를 더 안정적으로 반영할 수 있도록 설계되었다. 이를 통해 VideoMAE 의 표현을 훼손하지 않으면서도 T5 Decoder 가 처리하기 적합한 형태로 특징을 정규화하였다. 최종적으로 Adapter 는 입력 시퀀스를 일정한 길이로 맞추며, 각 타임스텝을 하나의 토큰 임베딩처럼 다룰 수 있도록 변환한다.

(4) T5 Decoder 기반 자연어 문장 생성

정제된 비디오 특징 시퀀스는 T5 Decoder 로 전달되어 최종 자연어 문장을 생성한다. 본 연구에서는 Encoder 없이 Decoder 만 사용되는 구조를 채택하여, VideoMAE+Adapter 가 사실상 Encoder 역할을 수행하도록 구성하였다. T5 Decoder 는 시각 특징 시퀀스와 언어 토큰을 교차적으로 활용하여 단어 단위로 문장을 생성하며, 수어 영상의 시각적 패턴을 영어 문장 구조에 대응시키는 역할을 수행한다. 이러한 방식은 비전 모델의 풍부한 표현력과 T5 의 언어 모델링 능력을 결합하여 수어 번역의 문장 생성 성능을 최대화하는 것을 목표로 한다.

(5) Track A 파이프라인의 기술적 의의



Track A는 RGB 기반 영상의 시각 정보를 유지하면서도, 오프라인 특징 추출과 Adapter 기반 구조를 활용해 제한된 GPU 환경에서도 학습 가능한 수어 번역 모델을 구성한 점에 의의가 있다. 대규모 비전 모델(VideoMAE)의 표현력을 활용하면서 실시간 추론과 효율적인 학습이 가능하며, 영상 기반 수어 번역 모델의 설계 방향을 제시하는 기반 구조로 활용될 수 있다.

3.1.2 Track B: 랜드마크 기반 번역 모델 파이프라인




그림 2. 랜드마크 기반 번역 모델 파이프라인

본 연구의 Track B는 RGB 영상을 직접 처리하는 Track A와 달리, MediaPipe를 통해 추출된 연속 랜드마크 시계열을 입력으로 하여 자연어 문장을 생성하는 경량 End-to-End 모델을 구축하였다. 전체 파이프라인은 (1) 랜드마크 기반 입력 시퀀스 구성, (2) Multi-Stream Embedding을 통한 특징 임베딩, (3) Transformer Encoder 기반 시계열 표현 학습, (4) T5 Decoder를 활용한 문장 생성으로 구성된다. Track B는 영상 정보 대신 구조화된 좌표 기반 표현을 사용함으로써 연산 효율성을 극대화하면서도 수어의 동작 패턴을 효과적으로 학습하는 것을 목표로 한다.

(1) 랜드마크 기반 입력 시퀀스 구성

랜드마크 입력은 MediaPipe Holistic으로부터 추출된 3D 좌표를 기반으로 하며, 최종 전처리 단계에서 얼굴·포즈·양손의 핵심 관절을 선택하여 시계열 형태의 텐서로 정리하였다. ipynb 기준으로 모델 입력은 $landmarks \in R^{B \times T \times J \times 2}$ 형태이며, 여기서 B 는 배치 크기, T 는 프레임 수, J 는 선택된 관절

수(코드 기준 약 95 개), 마지막 차원은 정규화된 (x, y) 좌표이다. 각 샘플은 실제 길이에 기반한 padding mask 와 함께 제공되며, 이는 Transformer Encoder 에서 시계열 관계를 학습할 때 유효 프레임과 패딩을 구분하는 데 사용된다.

(2) Multi-Stream Embedding 을 통한 랜드마크 특징 임베딩

정의된 ImprovedMultiStreamEmbedding 모듈은 Track B 의 핵심 입력 인코더로, 입력 랜드마크 $(B, T, J, 2)$ 를 여러 관절 스트림으로 분리한 뒤 Conv1d 기반 임베딩과 Residual Connection, GELU 활성화를 적용하여 손가락·팔 동작과 같은 지역적 패턴을 효과적으로 추출한다. 이러한 Multi-Stream 구조를 통해 각 신체 부위의 미세한 변화를 보존하면서도 통합 표현을 학습할 수 있으며, 최종적으로 랜드마크 시퀀스를 (B, T, d_{model}) 형태의 시퀀스 임베딩으로 변환하여 이후 T5 Decoder 가 처리할 수 있는 토큰 수준의 표현으로 매핑한다.

(3) Transformer Encoder 기반 시계열 구조 학습

최종 모델에서는 ImprovedMultiStreamEmbedding 을 통해 얻은 시퀀스 임베딩을 4층 Transformer Encoder 에 입력하여 수어의 시계열적 구조를 학습한다. 이 Encoder 는 Pre-LayerNorm 구조와 Residual Connection 을 사용해 안정적인 학습을 지원하며, self-attention 메커니즘을 통해 각 프레임 간의 시간적 관계—예를 들어 손의 이동 경로, 동작의 시작과 끝, 정지 구간—를 효과적으로 모델링한다. 또한 패딩 마스크를 활용하여 유효한 프레임에 대해서만 attention 을 계산함으로써 불필요한 연산을 제거하고 의미적 일관성을 유지한다. 이러한 과정을 거쳐 Encoder 는 입력 랜드마크 시퀀스를 의미적으로 정제된 특징 표현으로 변환하며, 이는 Decoder 가 문장을 생성할 때 참조하는 핵심 hidden state 로 사용된다.

(4) T5 Decoder 기반 자연어 생성

Track B 모델의 Decoder 는 ipynb 에서 구현된 SignLanguageT5Model 구조를 기반으로 하며, Encoder 가 생성한 시계열 특징을 입력으로 받아 T5ForConditionalGeneration 의 Decoder 를 그대로 활용해 자연어 문장을 생성한다. Decoder 는 Cross-Attention 을 통해 Encoder 의 hidden state 를 참조하며 토큰을 한 단계씩 생성하고, 학습 단계에서는 teacher forcing 을 사용해 안정적으로 수렴하도록 설계되어 있다. 추론 단계에서는 Beam Search, Top-k, Top-p 등 다양한 샘플링 기법을



적용할 수 있으며, 이를 통해 랜드마크 시퀀스로부터 영어 문장을 직접 생성하는 완전한 End-to-End 번역 구조가 완성된다.

(5) Track B 파이프라인의 기술적 의의

Track B는 RGB 영상 대비 훨씬 가벼운 랜드마크 좌표만을 사용하지만, Multi-Stream Embedding 과 Transformer Encoder 를 통해 시각적 구조 정보를 효과적으로 학습할 수 있다. 특히 ipynb 모델에서는 Conv1d 기반 스트림 처리, Residual-GELU 기반의 깊은 임베딩 구조, 4 층 Transformer Encoder 를 조합하여 수어의 시간적 패턴을 세밀하게 반영할 수 있도록 설계하였다. 또한 T5 Decoder 를 그대로 활용함으로써 강력한 언어 모델링 능력을 확보하여 경량 구조임에도 불구하고 복잡한 문장 생성 태스크를 수행할 수 있다. 이와 같은 구조는 실시간 적용 가능성, 경량화된 수어 번역 모델 연구 등에서 중요한 기술적 기반을 제공한다.

제 2 절 학습 설정 및 하이퍼파라미터 & 평가 지표 및 실험 환경

3.2.1 Track A: 학습 설정 및 하이퍼파라미터

본 연구의 Track A에서는 사전에 추출된 VideoMAE 기반의 영상 특징 벡터와 정제된 문장 텍스트를 사용하여 RGB 기반 수어 번역 모델을 학습하였다. 모든 영상은 VideoMAE-Base 모델을 활용해 64 프레임 단위의 고밀도 특징으로 변환되었으며, 이는 16 프레임씩 4 개 청크로 분할하여 처리한 후 (32×768) 차원의 시계열 임베딩으로 저장된다. 특징 벡터는 .npy 형태로 저장되어 학습 시작 시 메모리로 로딩되며, 텍스트는 필요 없는 구어적 표현의 제거 및 소문자 정규화를 포함한 전처리 후 모델의 정답 시퀀스로 사용된다. 전체 데이터는 학습·검증 세트로 9:1 비율로 분할하여 모델 성능 평가에 활용하였다.

모델 구조는 VideoMAE 에서 추출한 시계열 특징을 Transformer 기반의 Adapter 모듈로 변환한 뒤, 이를 T5-Base 디코더에 입력하여 자연어 문장을 생성하는 형태로 설계되었다. 입력 임베딩은 선형 투영(Linear $\rightarrow$ LayerNorm $\rightarrow$ ReLU $\rightarrow$ Dropout) 과정을 거쳐 T5 의 hidden size(768)에 맞추어 변환되며, 이후 위치 정보를 부여하기 위한 sinusoidal positional encoding 을 추가한다. 변환된 시계열 임베딩은 4 층의 Transformer Encoder 로 구성된 Adapter 를 통과하며, 여기서 Temporal



패턴과 문맥적 특징을 강화한 후 T5 디코더에 전달된다. 디코더는 beam search(beam size=4), 반복 방지 제약(no-repeat-ngram-size=3), repetition penalty 등의 생성 제약을 적용해 최종 번역 문장을 생성한다.

학습 과정에서는 T5 의 cross-entropy 기반 언어 생성 목적 함수를 사용하여 모델 파라미터를 업데이트하였으며, Colab Pro(T4 GPU) 환경의 제한을 고려하여 per-device batch size 4와 gradient accumulation step 4 를 적용해 실효 배치 크기 16 을 유지하였다. 최적화에는 AdamW 옵티마이저를 사용하였고, 학습률 $3e-4$, weight decay 0.02, 총 10 epoch 를 기본 설정으로 하였다. 또한 과적합 및 패턴 암기 현상을 방지하기 위해 입력 특징 시퀀스에 대해 15% 비율의 feature masking(SpecAugment 유사 기법)을 적용하였다. 학습 및 검증 단계에서는 sacreBLEU 지표를 사용하여 모델의 문장 생성 품질을 평가하고, 매 epoch 마다 검증 샘플을 출력하여 정성적 판단도 함께 수행하였다. 모든 학습 결과와 모델 가중치는 재현성을 확보하기 위해 지정된 디렉토리에 저장하였다.

3.2.2 Track B: 학습 설정 및 하이퍼파라미터

본 연구의 Track B 모델은 MediaPipe 기반 랜드마크 좌표를 Transformer 구조에 직접 입력하는 방식을 채택하여, 경량성을 유지하면서도 수어 시계열의 구조적 정보를 효과적으로 학습하도록 설계되었다. 학습 데이터는 DailyMoth-70h 와 How2Sign 에서 추출된 영상의 랜드마크를 사용하였으며, 전처리 단계에서 포즈(33 개), 왼손·오른손(21×2 개), 얼굴(468 개)을 포함한 543 개 전체 좌표를 정규화한 뒤 최종적으로 모델 입력에 적합한 95 개 핵심 포인트로 축소하였다. 각 포인트는 $(x,y,z,visibility)$ 형태로 구성되며, 좌표 정규화를 위해 신체 중심 기반 스케일링(body normalization), 양손 국소 min-max 정규화(hand minmax), 얼굴 특징에 대한 별도 min-max 정규화를 적용하였다. 정규화된 시퀀스는 하나의 시계열 벡터로 병합한 후, 일정 길이를 유지하기 위해 SASS(Stochastic Adaptive Sequence Sampling)를 적용하여 시퀀스를 균일한 길이로 맞추었다.

모델은 Multi-Stream CNN 기반의 프레임 임베딩 모듈과 4-층 Transformer Encoder 로 구성되며, 각 타임스텝의 좌표 벡터는 1 차적으로 1D convolution 을 통해 지역적 패턴을 추출하고, 이후 선형



투영(linear projection)을 거쳐 $d_{model} = 512$ 차원의 잠재공간으로 매핑된다. Transformer Encoder 는 8-head self-attention, feed-forward dimension 2048, dropout 0.15 를 사용하여 시계열 내 장기 의존성을 학습하도록 설계되었다. 디코더로는 T5-small 을 사용하였으며, Encoder 출력 임베딩을 T5 입력 형태에 맞도록 변환하여 자연어 문장 생성에 활용하였다. 토큰나이저는 T5-small 의 기본 vocabulary 를 사용하였으며, 최대 출력 길이는 64 토큰으로 설정하였다.

학습 과정에서는 AdamW 옵티마이저를 사용하였고, 초기 학습률은 5×10^{-5} , weight decay 는 0.01 로 설정하였다. 전체 스텝의 10%에 해당하는 warm-up 구간을 포함한 linear-decay 스케줄러를 적용하여 안정적인 수렴을 유도하였다. 배치 크기는 8로 설정하였으며, GPU 환경을 고려하여 gradient accumulation 을 4 로 두어 실효 배치 크기 32 로 학습을 진행하였다. 모델의 일반화 성능을 높이기 위해 랜드마크 수준 좌표에 대한 dropout 및 시퀀스 마스킹 기반의 데이터 증강을 함께 적용하였다. 학습은 10 epoch 동안 수행되었으며, 매 epoch 종료 시 validation loss 와 BLEU 스코어를 평가하였다. 성능이 가장 우수한 모델은 두 기준(loss 및 BLEU)에 대해 각각 별도로 저장하여 재현성과 안정성을 확보하였다. 최종적으로 학습된 모델은 추론 단계에서 정규화된 랜드마크 시퀀스를 입력받아 T5 디코더를 통해 자연어 번역 문장을 생성하도록 구성되었다.

3.2.3 평가 지표 및 실험 환경

본 연구에서는 개발된 Two-Track 수어 번역 모델의 성능을 정량적·정성적으로 평가하기 위해 다음과 같은 지표들을 활용하였다.

- **BLEU-4 (Bilingual Evaluation Understudy):** 생성 문장과 정답 문장 간의 n-gram 정확도를 기반으로 번역 품질을 측정하는 대표 지표로, 수어-영어 번역의 문장 정확도를 평가하는 데 활용하였다.
- **ROUGE-L (Recall-Oriented Understudy for Gisting Evaluation):** 두 문장 간 최장 공통 부분 수열(Longest Common Subsequence; LCS)을 사용하여 구조적 유사성을 평가한다. 모델이 전체 문장의 흐름과 구조를 얼마나 잘 재현하는지 확인하기 위한 지표로 사용하였다.



- **METEOR (Metric for Evaluation of Translation with Explicit ORdering):** 어간 추출(stemming), 동의어 매칭을 고려해 의미적 유사성을 평가하는 지표로, BLEU 가 포착하지 못하는 문장 의미 보존 여부를 보완적으로 파악하였다.
- **Inference Time (ms/sample):** 단일 샘플 번역에 소요되는 평균 처리 시간을 통해 각 모델의 실시간성 및 배포 가능성을 확인하였다.
- **GPU Memory Usage, Model Size:** 모델의 파라미터 수와 추론 시 점유하는 메모리 사용량을 측정하여 Track A 와 Track B 의 경량성과 효율성을 비교하였다.
- **Throughput (FPS):** 초당 처리할 수 있는 프레임 수로, 영상 기반 수어 번역 모델의 실제 동작 가능성을 평가하는 효율성 지표로 사용하였다.

모든 실험은 Google Colab Pro 환경에서 수행되었으며, GPU 는 NVIDIA T4 를 기본으로 사용하였다. 프레임워크는 PyTorch 2.0 과 HuggingFace Transformers 를 기반으로 구성하였으며, Decord 를 활용해 영상 프레임을 효율적으로 로드하였다. 동일한 랜덤 시드 설정 및 체크포인트 저장 방식을 적용하여 실험 재현성을 확보하였고, 데이터 전처리·특징 추출·학습·추론 단계는 두 모델 모두 일관된 파이프라인 체계를 유지하였다.



제 4 장 결론

제 1 절 연구 결과 및 보고

4.1.1 Track A 최종 모델




그림 3. Track A 최종 모델 결과 및 시연 예시

본 연구의 Track A 실험에서는 리소스 제약을 극복하기 위해 사전 학습된 VideoMAE-Base 를 동결(Frozen)하고 T5-Base 디코더를 결합한 오프라인 특징 추출(Offline Feature Extraction) 파이프라인을 적용하였다. 64 프레임 단위의 청크(Chunking) 처리를 통해 시공간적 문맥 정보를 보존하려 시도하였으나, 최종 테스트 데이터에서 BLEU-4 점수 1.66 에 그치며 유의미한 번역 성능을 확보하는 데는 한계를 보였다. 학습 과정을 살펴보면 Training Loss 는 0.16 까지 지속적으로 감소한 반면, Validation Loss 는 Epoch 6 시점 이후 오히려 상승하는 전형적인 과적합(Overfitting) 양상이 관찰되었다.

성능 지표와 생성 결과를 상세히 분석하면 모델이 수어의 시각적 특징을 온전히 학습하지 못해 '유창한 환각(Fluent Hallucination)' 현상이 발생한 것으로 파악된다. T5-Base 모델은 문법적으로 자연스러운 문장을 생성하였으나, 실제 수어 동작(예: 어깨 운동)을 전혀 다른 문맥(예: 요가 자세)으로

오역하는 등 시각 정보(Visual Tokens)와 텍스트 간의 정렬(Alignment)에 실패하였다. 이는 일반 행동 인식 데이터(Kinetics-400)로 학습된 인코더가 수어의 핵심인 미세한 손가락 움직임(Fine-grained Motion)을 포착하지 못한 결과로 분석되며, 결과적으로 제한된 리소스 환경에서는 픽셀 기반 접근보다 랜드마크 기반 접근(Track B)이 더 효율적임을 시사한다.

4.1.2 Track B 최종 모델




그림 4. Track B 최종 모델 결과 (Loss, BLEU 측정)

최종 실험 Exp-8(Learning Rate = $5e-05$, Encoder Layers = 4)에서는 SASS(Stochastic Adaptive Sequence Sampling) 기법과 데이터 증강을 모두 적용한 T5 기반 모델이 테스트 데이터에서 BLEU-4 점수 44.41 이라는 매우 높은 성능을 기록하였다. 학습 과정을 살펴보면 검증 손실(Validation Loss)은 2.1526까지 안정적으로 감소하였으며, 듀얼 저장 전략(Dual Save Strategy)을 통해 최적의 성능을 보인 시점의 가중치를 확보하였다.

성능 지표를 상세히 분석하면 BLEU-4는 44.41로 매우 높은 수치를 보였으나, 문장의 재현율과 구조적 유사도를 나타내는 ROUGE-L 은 13.08, METEOR 는 8.26 으로 상대적으로 낮게 집계되어 지표 간 괴리가 나타났다. 반면 추론 효율성 측면에서는 약 7,440 만 개의 파라미터로 샘플당 평균 38.74ms 의 추론 시간과 25.81 samples/sec 의 처리량을 기록하여, 엣지 디바이스에서도 구동 가능한 경량화 및 실시간성을 확보했음을 확인하였다.



정답 (Ground Truth):
 "Four people were killed in the first location and"

예측 (Prediction):
 "a number of people who were killed in the shooting"

단어 겹침률: 35.7%

--- Sample 1 ---
 Target : Politico said according to its sources,
 Predict: he was a member of the U.S. Army.

--- Sample 2 ---
 Target : Here are today's top stories.
 Predict: Here are today's top stories.

--- Sample 3 ---
 Target : It will be up to Fulton County (Atlanta area) District Attorney
 Predict: The U.S. Department of Justice said

그림 5. Track B 시연 예시

그러나 실제 번역 샘플(Qualitative Analysis)을 분석한 결과, 모델이 입력된 수어 랜드마크의 시각적 정보보다는 학습 데이터(How2Sign)에 빈번하게 등장하는 "U.S. Army", "Department of Justice" 등 특정 정치·뉴스 도메인의 텍스트 분포에 과도하게 의존하여 문장을 생성하는 언어 모델 편향(Language Model Bias) 경향이 확인되었다.

즉, 최종 모델은 아키텍처 최적화와 샘플링 기법 도입을 통해 수치적으로는 비약적인 성능 향상과 우수한 연산 효율성을 달성하였으나, 정성적 평가에서는 특정 구문이 반복적으로 생성되는 과적합(Overfitting) 및 환각(Hallucination) 현상이 관찰되어 도메인 일반화에 대한 추가적인 개선 필요성을 시사한다.

4.1.3 성능 측정 요약

Track A 데이터셋을 활용한 실험의 경우 BLEU 점수가 1 점대 수준에 머무르는 등 유의미한 학습 결과가 도출되지 않아, 본 성능 지표 분석에서는 제외하고 Track B 의 실험 결과만을 중점적으로 기술하였다.



성능 지표 (Performance Metrics)	측정 값(Value)	비고 (Note)
BLEU-4	44.41	n-gram 정밀도 (매우 높음)
ROUGE-L	13.08	문장 구조 재현율 (낮음)
METEOR	8.26	의미적 유사도 (낮음)
Inference Time	38.74 ms/sample	추론 속도
Throughput	25.81 samples/sec	처리량
Total Parameters	74,403,840	모델 크기 (경량)
GPU Memory Usage (Peak)	739.43 MB	메모리 효율성

표 1. Track B 주요 성능 지표

본 실험에서 Track B 모델은 BLEU-4 기준 44.41 이라는 이례적으로 높은 수치를 기록했으나, 이를 단순한 번역 성능의 향상으로 해석하기에는 ROUGE-L(13.08) 및 METEOR(8.26) 점수와의 괴리가 매우 크다. 정성적 평가(Qualitative Analysis) 결과, 모델이 입력된 수어 동작(Encoder Input)의 문맥을 정확히 파악하기보다는 학습 데이터(How2Sign 등)에 빈번하게 등장하는 특정 정치·뉴스 도메인 용어(예: "U.S.", "Army", "Government")를 반복적으로 생성하는 편향(Bias) 현상이 관찰되었다.

이는 강력한 사전 학습 모델인 T5 Decoder가 시각적 특징(Landmark Feature)보다 텍스트 데이터의 사전 확률 분포에 과도하게 의존하는 '언어 모델 우세(Language Model Dominance)' 현상에 기인한 것으로 분석된다. 즉, 높은 BLEU 점수는 모델이 수어를 완벽히 이해했다기보다 정답 문장(Ground Truth)과 모델이 편향적으로 생성한 문구들이 우연히 겹치며 발생한 착시 현상일 가능성이 높다.

하지만 시스템 효율성 측면에서는 38.74ms의 빠른 추론 속도와 740MB 수준의 낮은 메모리 점유율을 달성하여, 엣지 디바이스(Edge Device) 탑재 가능성과 실시간 처리 성능은 충분히 입증되었다. 향후 연구에서는 이러한 텍스트 편향을 해소하기 위해 'Word Dropout'과 같은 정규화 기법을 도입하거나 일상 대화 데이터셋의 비중을 늘려 Decoder가 시각 정보(Encoder)에 더 집중하도록 개선할 필요가 있다.



4.1.4 LLM 검증: 명시적 피처 주입의 효용성

앞서 논의한 Track A, B 모델의 성능 지표에 더해, 본 연구에서는 수어(ASL)와 영어 간의 본질적인 언어학적 불일치(Linguistic Mismatch)를 해소하기 위한 별도의 심화 검증을 수행하였다. 이를 위해 표준 Transformer 모델에 언어학적 정보를 직접 주입하는 ‘명시적 피처(Explicit Feature) 모델’을 구축하고, 단순 데이터 증강과 피처 주입이 번역 품질의 ‘구조적 완성도’와 ‘의미적 전달력’에 미치는 영향을 비교 분석하였다.

(1) 실험 구성 및 비교군 설정

검증은 ASLG-PC12 데이터를 기반으로 가공된 총 4 개의 실험군(G0~G3)을 통해 진행되었다.

그룹명	데이터 성격	특징 및 구성	데이터 파일명
G0 (Baseline)	원본 데이터	전처리만 수행된 기본 Gloss 데이터. 피처를 사용하지 않았다	train_G0.csv
G1 (Augmentation)	증강 데이터	언어학적 분석(기능어 삽입, 어순 재배열)을 통해 인위적으로 생성된 데이터를 원본에 추가하여 학습량을 늘렸다	train_G1.csv
G2 (Features)	피처 주입	원본 데이터에 품사 정보 및 구문 정보를 담은 명시적 피처 벡터를 함께 제공한다	train_G2.csv
G3 (Hybrid)	하이브리드	증강된 데이터(G1)와 명시적 피처(G2)를 모두 활용하여 시너지 효과를 검증한다	train_G3.csv

표 2. 실험 구성 및 비교군 설정

(2) 검증 결과 분석

① 의미적 전달력의 획기적 개선 (G2 vs G0)

실험 결과, 명시적 피처를 주입한 G2 모델은 의미적 유사도를 평가하는 METEOR 점수에서 15.06 을 기록하며, 베이스라인(G0, 13.14) 대비 약 14.6%의 성능 향상을 보였다. 즉, 비록 기계적인 단어 매칭 정확도인 BLEU 점수는 G0(2.61)가 G2(2.02)보다 소폭 높았으나, METEOR 의 급격한 상승은 피처 주입이 모델로 하여금 단순 암기를 넘어 문맥을 파악하고 적절한 유의어를 선택(Lexical Choice) 하게 만드는 데 강력한 가이드 역할을 했음을 시사한다. 이는 번역의 핵심인 ‘의미 전달’ 측면에서 피처 주입이 매우 유효함을 입증한다.



② 데이터 증강의 초기 학습 한계 (G1, G3)

단순 데이터 증강을 적용한 G1 과 하이브리드 모델 G3 는 초기 학습 단계(1 Epoch)에서 과소적합(Underfitting) 현상을 보였다. 즉, 인위적으로 변형된 어순과 삽입된 기능어들이 초기에는 모델에게 노이즈(Noise)로 작용하여 수렴을 지연시킨 것으로 분석된다. 다만, G3 모델이 G1 대비 성능 회복세를 보인 점은 충분한 학습 시간이 주어질 경우 하이브리드 전략이 구조적 손실을 방어할 잠재력이 있음을 보여준다.

(3) 소결

본 검증을 통해 수어 인식 프로젝트의 최종 목표인 '자연스러운 번역'을 위해서는 단순한 데이터 양의 증대보다 언어학적 피처를 활용한 모델의 내재적 이해도 향상이 더욱 효과적인 접근법임을 확인하였다. 이는 향후 Track A, B 모델 고도화 시 구조적 정확도뿐만 아니라 의미적 맥락을 보존하는 메커니즘이 필수적으로 고려되어야 함을 시사한다.

제 2 절 한계점 및 향후 연구 방향

4.2.1 해당 연구의 한계점

본 연구는 수어(Sign Language)의 시각적 표현을 자연어 문장으로 변환하는 Two-Track 기반의 End-to-End 수어 번역 시스템을 개발하였으나, 다음과 같은 한계점을 내포하고 있다.

첫째, 사용 가능한 수어 데이터의 양이 절대적으로 부족하여 모델의 일반화 성능을 충분히 확보하는데 제약이 있었다. 본 연구에서는 How2Sign 과 Daily70 을 결합하여 총 15,484 개의 학습 데이터를 확보하였으나, 이는 일반적인 자연어 처리나 컴퓨터 비전 분야에서 사용되는 대규모 데이터셋(예: YouTube-ASL 의 1,000 시간)에 비해 현저히 작은 규모이다. 특히 제한된 컴퓨팅 환경(Colab Pro, T4 GPU, 15GB VRAM)으로 인해 초대규모 데이터셋의 활용이 불가능하였으며, 이로 인해 학습 곡선 분석에서 초기 Epoch 이후 Validation Loss 가 상승하는 과적합(Overfitting) 현상이 관찰되었다.

둘째, 연구에 사용된 데이터셋이 특정 언어 및 도메인에 편중되어 있어 다양한 수어 환경으로의 확장 가능성이 검증되지 못하였다. How2Sign 데이터셋은 그린 스크린 환경에서 촬영된 미국 수어(ASL) 교육



영상으로 구성되어 있어 배경 노이즈가 적고 통제된 환경의 특성을 가진다. 이에 따라 실제 수어 사용 환경에서 발생할 수 있는 조명 변화, 복잡한 배경, 카메라 품질 차이 등 다양한 요인에 대한 모델의 강건성(Robustness)을 충분히 검증하지 못하였다. 또한 한국 수어(KSL), 일본 수어(JSL) 등 다른 수어 체계로의 적용 가능성은 향후 추가적인 데이터 수집 및 실험을 통해 검증되어야 할 과제로 남아있다.

셋째, Track A(영상 기반 모델)에서 사용된 사전학습 모델의 도메인 불일치 문제로 인해 수어의 핵심적인 시각 정보를 포착하는 데 한계가 있었다. 일반 행동 인식 데이터(Kinetics-400)로 사전학습된 VideoMAE 를 동결(Frozen)하여 사용함에 따라 수어의 핵심인 미세한 손가락 움직임(Fine-grained Motion)과 공간적 설정(Spatial Configuration)을 충분히 포착하지 못하였다. 이로 인해 모델이 영상의 전반적인 분위기는 파악하나 구체적인 수어 단어를 정확히 매핑하지 못하는 '유창한 환각(Fluent Hallucination)' 현상이 발생하였다.

넷째, 수어가 가지는 복합적 시각 언어로서의 특성을 완전히 반영하는 데 기술적 어려움이 존재하였다. 수어는 손동작(수지 기호)뿐만 아니라 얼굴 표정, 시선, 눈썹 움직임, 입모양, 신체 방향 등의 비수지 기호(Non-manual Markers)가 결합된 고차원적 시각 언어이다. Track B 에서는 Face Stream 을 추가하여 40 개의 핵심 표정 포인트를 반영하였으나, 시선의 방향성이나 미세한 감정 표현 등 비수지 기호의 모든 뉘앙스를 완벽하게 포착하기에는 여전히 한계가 있었다.

4.2.2 향후 연구 방향

수어 번역 기술의 실용성을 높이기 위해서는 데이터 확장, 모델 적응력 강화, 언어적 확장 등 다각적 연구가 요구된다. 우선 수어 데이터는 절대적으로 부족하므로 크라우드소싱 기반의 데이터 수집, 반자동 라벨링, 기하학적 증강 및 SASS 와 같은 고도화된 데이터 증강 전략을 도입하여 데이터 규모와 다양성을 지속적으로 확대해야 한다. 또한 Self-Supervised Learning 기반 사전학습을 강화하여 제한된 데이터 환경에서도 모델의 일반화 성능을 높일 필요가 있다. 아울러 본 연구에서 확인된 '유창한 환각' 문제를 완화하기 위해 비전 인코더를 수어 데이터에 맞게 추가 학습하거나 Adapter·LoRA 기반의 파라미터 효율적 학습 기법을 적용하여 손가락 움직임과 공간적 설정을 더욱 정밀하게 포착해야



한다. 마지막으로 ASL 중심의 현재 연구 범위를 KSL, JSL 등 다양한 수어 체계와 한국어, 일본어 등 다국적 자연어로 확장하기 위해 다수어 병렬 코퍼스 구축과 언어 간 전이 학습 기법의 적용이 필요하다.



참고문헌

1. Rust et al., "Towards Privacy-Aware Sign Language Translation at Scale", arXiv:2402.09611.
2. Hwang et al., "An Efficient Gloss-Free Sign Language Translation Using Spatial Configurations and Motion Dynamics with LLMs", NAACL 2025.
3. Tong et al., "VideoMAE: Masked Autoencoders are Data-Efficient Learners for Self-Supervised Video Pre-Training", NeurIPS 2022.
4. Raffel et al., "Exploring the Limits of Transfer Learning with a Unified Text-to-Text Transformer", JMLR 2020.
5. Duarte et al., "How2Sign: A Large-Scale Multimodal Dataset for Continuous American Sign Language", CVPR 2021.
6. S. Guewou, X. Du, G. Shakhnarovich, and K. Livescu, "SignMusketeers: An Efficient Multi-Stream Approach for Sign Language Translation at Scale", arXiv:2406.08097v2 [cs.CL], 2025.
7. Y. Kim, M. Kwak, D. Lee, Y. Kim, and H. Baek, "Keypoint based Sign Language Translation without Glosses", arXiv:2204.10511v2 [cs.CV], 2022.

